Data Canvas – Projet fil rouge

Groupe : D

Sujet : Fraude bancaire à l'ouverture de compte

Membres et rôles :

Chef de projet : Sandrine Yu

Responsable données : Massilia Moungad

Analyste : N'da Paul Samuel Kakou

Développeur : Youcef Elmouhtadi Lagraa & Elie Inkune Mboyo

Communicant : Yanis Ziouani

1. Besoin métier

Une banque en ligne reçoit des milliers de demandes d'ouverture de compte par jour, dont environ 1% sont frauduleuses (usurpation d'identité, comptes « mules »). Elle veut bloquer ces ouvertures avant qu'elles ne génèrent des pertes financières et un risque réglementaire (LCB-FT), sans freiner la conversion des clients légitimes.

2. Décision à améliorer

Pour chaque demande soumise en ligne, un score automatique oriente le dossier vers 3 issues : acceptation automatique, revue manuelle (KYC renforcé) ou refus après revue par un analyste. Le seuil est contraint par la capacité opérationnelle : au maximum 5% des demandes légitimes sont envoyées en contrôle. Aucun refus n'est prononcé sans validation par un analyste humain.

3. Question data

Question prédictive : Quelle est la probabilité P(fraude=1) qu'une demande d'ouverture de compte soumise à l'instant t soit frauduleuse, à partir des données renseignées dans le formulaire ?

Question explicative : Quels sont les facteurs comportementaux et d'ancrage (vélocité, ancienneté, profil) qui différencient une demande légitime d'une tentative d'usurpation ou de compte mule ?

Type de problème : Classification binaire supervisée à fort déséquilibre de classes.

4. Variable cible

Nom : fraud_bool

Valeurs : 1 = demande frauduleuse, 0 = demande légitime.

Répartition attendue : Environ 1,1% de fraudes (11 029 cas sur 1 M de lignes).

5. Unité d'analyse et granularité

Une ligne = 1 demande d'ouverture de compte individuelle (1 dossier).

Nombre de lignes : 1 000 000 de demandes sur une période de 8 mois.

Clé d'identification : Pas d'identifiant unique disponible ; aucune agrégation préalable nécessaire.

6. Moment de la prédiction

La prédiction est réalisée en temps réel (t=0) dès la soumission du formulaire, avant toute vérification manuelle et avant la création effective du compte.

Seules les variables capturées au moment du dépôt sont exploitables. Les variables credit_risk_score, proposed_credit_limit et device_fraud_count doivent être auditées pour éviter tout biais d'antériorité.

7. Variables explicatives candidates

Variable	Type (continue, discrète, nominale, ordinale)	Connue au moment de la décision ?	Hypothèse sur son lien avec la cible

velocity_6h, zip_count_4w, device_distinct_emails_8w	Quantitatives continues / discrètes	Oui	H1 (Vélocité) : Des pics de demandes rapprochés depuis un même endroit ou appareil indiquent une attaque automatisée (botnet/mules).
current_address_months_count, bank_months_count, prev_address_months_count	Quantitatives discrètes	Oui	H2 (Ancrage) : L'absence d'historique (ou des valeurs -1 codant l'absence de donnée) augmente le risque d'usurpation d'identité.
credit_risk_score, proposed_credit_limit	Quantitatives	À vérifier ($t = 0$)	H3 (Financier) : Un score très dégradé est corrélé au risque de fraude, sous réserve de vérification du risque de *data leakage*.
customer_age, income	Ordinales / Quantitatives	Oui	Variables à impact fort mais identifiées comme sensibles (audit d'équité requis).
employment_status, housing_status	Nominales	Oui	Proxys sociaux à analyser avec précaution (risques de biais discriminatoires).

8. Sources de données

Source	Interne / externe	Mode d'accès	Granularité	Période couverte	Licence
Source imposée : Bank Account Fraud Dataset Suite (Feedzai - Base.csv)	Externe (synthétique issue du réel)	Téléchargement manuel Kaggle	1 ligne = 1 demande d'ouverture	8 mois (mois 0 à 7)	CC BY-NC-SA 4.0
Source complémentaire :Rapport OSMP (Banque de France)	Externe	Fichier PDF / Open Data publique	Macroéconomique nationale (agrégats annuels)	Données annuelles	Licence Etalab (Open Data)

9. Évaluation des sources (check-list)

Source imposée (Base.csv) :

Pertinence : parfaite pour le problème métier, 1 M de lignes, bonne fraîcheur, pas de valeurs NaN brutes (mais codées en -1).

Source complémentaire (OSMP Banque de France) :

Pertinence : Élevée pour le cadrage métier. Elle permet d'établir les benchmarks nationaux de fraude bancaire et d'usurpation d'identité en ligne.
Couverture : France entière, agrégée sur l'ensemble des établissements bancaires nationaux.
Fraîcheur : Publication annuelle (mises à jour régulières de la Banque de France).
Granularité : Données macroéconomiques globales par an et par canal (aucune donnée au niveau individuel/dossier).
Qualité : Données officielles, auditées et consolidées par les régulateurs bancaires.
Biais et limites : Ne comptabilise que les fraudes avérées et signalées par les banques (sous-estimation possible des attaques bloquées en amont).
Licence et Droits : Open Data publique (Informations publiques gouvernementales sous licence Etalab).

Argumentation du rejet : Les données de la Banque de France servent de benchmark macroéconomique pour justifier l'intérêt métier dans notre Data Canvas (taux de fraude cible). Cependant, elles sont rejetées comme variable d'entrée du modèle de Machine Learning car leur granularité est annuelle/nationale, alors que notre modèle doit prédire la fraude dossier par dossier à la seconde près (t=0).

10. Critère de succès

Métrique principale : Recall >> 50% pour un taux de faux positifs (FPR) fixé à 5% sur l'échantillon de test (mois 6 et 7).

Exclusion : L'Accuracy est exclue car un modèle prédisant 0% de fraude obtiendrait 98,9% d'Accuracy tout en échouant sur le besoin métier.

Coût d'un faux négatif (fraude ratée) : Pertes financières directes + sanctions LCB-FT.

Coût d'un faux positif (client légitime contrôlé) : Friction sur l'expérience client et coût opérationnel de la revue manuelle.

11. Parties prenantes

Utilisateurs directs : Analystes KYC / Fraude (chargés d'effectuer la revue manuelle des 5% de dossiers ciblés).

Impactés par le modèle : Candidats à l'ouverture d'un compte (expérience fluide vs contrôle renforcé).

Sponsors : Direction des risques, équipe Conformité / LCB-FT.

12. Contraintes éthiques, juridiques et techniques

Données personnelles & RGPD : Article 22 (interdiction de la décision 100% automatisée entraînant un refus sans recours humain), obligation d'explicabilité de la décision, minimisation des données, base légale LCB-FT.

Risques de discrimination : Mesure du ratio d'équité des faux positifs entre groupes d'âge (ratio FPR entre <50ans et >>50 ans maintenu entre 0,8 et 1,25).

Contraintes techniques : Temps de réponse temps réel (t=0) exigé lors du dépôt.

13. Risques de fuite de données et limites

Data Leakage : Risque de fuite si des variables calculées post-décision sont utilisées (ex. credit_risk_score ou proposed_credit_limit). Prévention par séparation temporelle stricte (Train : mois 0−5, Test : mois 6−7).

Colonnes constantes : device_fraud_count est constante et donc supprimée.

Limites : Jeu généré à partir de données réelles ; les seuils ne sont pas transposables sans ré-étalonnage sur des flux réels d'exploitation.

14. Démarche prévue

Extraction & Nettoyage : Remplacement des -1 par NaN, ajout d'indicateurs <col>_manquant, typage (int8, category), export Parquet et traçabilité SHA-256 (lineage.json).

Exploration (EDA) : Analyse des distributions, vérification des 3 hypothèses métiers et audit des biais d'équité (Module 2).

Modélisation de référence : Baseline avec découpage temporel strict (mois 0−5 vs 6−7).

Modèles avancés & Évaluation : Optimisation du Recall à FPR =5%.

Restitution & Mise en service : Présentation du pipeline, applicabilité des prédictions et cadrage éthique RGPD.

Annexe:

Usage de l'IA:

L'IA a servi d'assistant de codage pour accélérer les tâches répétitives (structure du pipeline, fonctions utilitaires, structuration design des slides).

L'expertise humaine est restée centrale pour surmonter ses limites :
Contrôle des biais et fuites : Correction des risques de fuite temporelle (t=0) non anticipés par l'IA.
Choix métier : Sélection du Recall à FPR fixe (là où l'IA privilégiait l'Accuracy par défaut).
Conformité : Validation systématique des contraintes RGPD (art. 22) et de l'explicabilité.