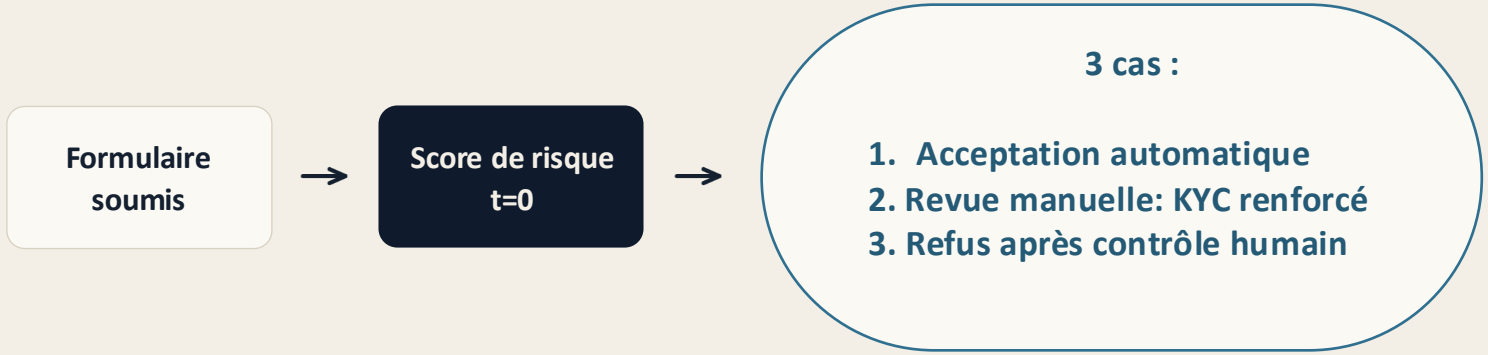
1. Le Problème

Anticiper la fraude à l'ouverture à partir du dépôt de dossier

Enjeu :
Bloquer la fraude en temps réel (mules, usurpation) et préserver l'expérience des clients légitimes

Volume :
1,1% de fraude sur des milliers de dossiers quotidiens

- **Décision :**



- **Cadre :**

Cible :
fraud_bool : 1 = fraude, 0 = légitime. Classification binaire, très déséquilibrée.

Unité d'analyse :
Une demande d'ouverture de compte
1 ligne = 1 dossier (Base.csv).

Moment de la prédiction :
À la soumission du formulaire, avant vérification et ouverture du compte.

Chiffre :
Recall ≥ 50 % de détection
Taux de contrôles fixé à 5%

2. Les Données

1M
demandes d'ouverture

8 mois
train 0–5 · test 6–7

32
colonnes, dont la cible

1,1 %
de fraude

Base.csv (Feedzai) :

Accès : Téléchargement manuel Kaggle
Granualarité : 1 ligne = 1 demande, sans identifiant
Licence : CC BY-NC-SA 4.0 (à confirmer)
Usage : Modélisation cible et 30 variables

Rapport OSMP (banque de France) :

Accès : Rapport PDF annuel (OSMP)
Granularité : Agrégats nationaux, aucune clé commune
Licence : Publication officielle, citation
Usage : Contexte seulement : non joignable, périmètre paiements

Pipeline notebook :

CSV Local → SHA-256 → Contrôle qualité → -1 : manquants → Split temporel → Parquet, lineage

3. Les Risques

Maîtriser les risques opérationnels et éthiques du modèle

Fuites de données

Variables : credit_risk_score, proposed_credit_limit
Action : audit à t = 0 + split temporel strict

Biais

Variables sensibles : âge, revenu, statut logement
Objectif : ratio de FPR entre 0,8 et 1,25 selon l'âge

Données personnelles

Respect : principe de minimisation LCB-FT
Conformité : pas de refus 100% auto (RGPD art. 22)

Limites

Dataset : synthétique (8 mois d'historique)
Risque : dérive des données face aux nouveaux fraudeurs